

07 — Séries temporelles & prévision

Objectif (data science). Analyser la dynamique de la production scientifique de l'UGA : tendance (CAGR, régression linéaire), trajectoire de l'accès ouvert, et **prévision** à court terme (lissage exponentiel de Holt). Données réelles OpenAlex, agrégées en direct.

```
[1] import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from statsmodels.tsa.holtwinters import ExponentialSmoothing


from lib import set_seeds, OpenAlexClient, load_mart
from lib.viz import new_axes, BRAND, ACCENT

set_seeds()
oa = OpenAlexClient()
```

1. Série annuelle de production (corpus complet)

L'agrégation ``group_by`` par année donne le volume complet en un appel. On écarte l'année courante (incomplète) pour l'analyse de tendance.

```
[2] buckets = oa.group_by("publication_year")
series = (
    pd.DataFrame(buckets)
    .assign(year=lambda d: d["key"].astype(int))
    .query("2010 <= year <= 2024")
    .sort_values("year")
    .set_index("year")["count"]
)
ax = new_axes("Production annuelle UGA (corpus complet)", xlabel="Année", ylabel="Publications")
series.plot(ax=ax, marker="o", color=BRAND)
ax.set_ylim(bottom=0)
plt.tight_layout()
plt.show()
series
```



```
year
2010    2842
2011    3421
2012    3747
2013    4467
2014    5250
2015    6511
2016    7656
2017    8261
2018    8752
2019    9140
2020    9927
2021    9786
2022    9652
2023   10118
2024    9875
Name: count, dtype: int64
```

2. Tendance : CAGR et régression linéaire

Le CAGR (taux de croissance annuel moyen) résume la dynamique ; la régression linéaire en donne la pente moyenne sur la période.

```
[3] first, last = series.iloc[0], series.iloc[-1]
n_years = series.index[-1] - series.index[0]
cagr = (last / first) ** (1 / n_years) - 1

slope, intercept = np.polyfit(series.index, series.values, 1)
print(f"Production {series.index[0]} : {first:,} → {series.index[-1]} : {last:,}")
print(f"CAGR (taux de croissance annuel moyen) : {cagr:.1%}")
print(f"Pente de régression linéaire : {slope:+.0f} publications/an")
```


```
Production 2010 : 2,842 → 2024 : 9,875
CAGR (taux de croissance annuel moyen) : 9.3%
Pente de régression linéaire : +574 publications/an
```

3. Prévision par lissage exponentiel (Holt)

On projette les deux prochaines années avec un modèle de Holt (tendance additive).
C'est une prévision déterministe, reproductible et explicable.

```
[4] model = ExponentialSmoothing(series.astype(float), trend="add", seasonal=None,
fit = model.fit()
forecast = fit.forecast(2)

ax = new_axes("Production : historique et prévision (Holt)", xlabel="Année", y
series.plot(ax=ax, marker="o", color=BRAND, label="observé")
forecast.plot(ax=ax, marker="o", linestyle="--", color=ACCENT, label="prévision
ax.legend()
ax.set_ylim(bottom=0)
plt.tight_layout()
plt.show()
print("Prévision :", {int(y): int(round(v)) for y, v in forecast.items()})
```




```
Prévision : {2025: 9881, 2026: 9886}
```

4. Trajectoire de l'accès ouvert

On confronte la part d'accès ouvert par année (mart `overview``) à la tendance de production : l'ouverture progresse fortement sur la décennie.

```
[5] overview = load_mart("overview")
oa_series = pd.DataFrame(overview["oaByYear"]).query("2010 <= year <= 2024").se
ax = new_axes("Trajectoire de l'accès ouvert", xlabel="Année", ylabel="Part en
oa_series.plot(ax=ax, marker="o", color=ACCENT)
ax.set_ylim(0, 1)
plt.tight_layout()
plt.show()
print(f"Accès ouvert : {oa_series.iloc[0]:.0%} ({oa_series.index[0]}) → {oa_ser
```



Accès ouvert : 42% (2010) → 70% (2024)

Lecture. La production de l'UGA a crû régulièrement sur la décennie (CAGR positif, pente de plusieurs centaines de publications par an), avec un plateau sur les dernières années : la prévision de Holt prolonge donc prudemment ce palier récent plutôt qu'une croissance soutenue. En parallèle, la part d'accès ouvert progresse nettement, signe d'une politique de science ouverte effective.

Les années 2025-2026, incomplètes à la date d'exécution, sont volontairement exclues de l'ajustement pour ne pas introduire de fausse rupture de tendance.